TALLER PRÁCTICO

Taller 2: ¿Puedes Predecir el Fútbol Mejor que las Casas de Apuestas?

Machine Learning I (ML1-2026I) — Regresión Lineal, Logística y Feature Engineering

Julián Zuluaga — Docente

19 de marzo de 2026

TALLER 2: ¿Puedes Predecir el Fútbol Mejor que las Casas de Apuestas?

Regresión Lineal, Logística y Feature Engineering con Datos Reales de la Premier League 2025-26

Curso: Machine Learning I (ML1-2026I) — Universidad Externado de Colombia **Modalidad:** En parejas **Peso:** 15% de la nota final **Fecha límite:** Domingo 29 de marzo de 2026, 11:59 PM (hora Colombia, GMT-5) **Entrega:** Repositorio GitHub + URL del dashboard desplegado

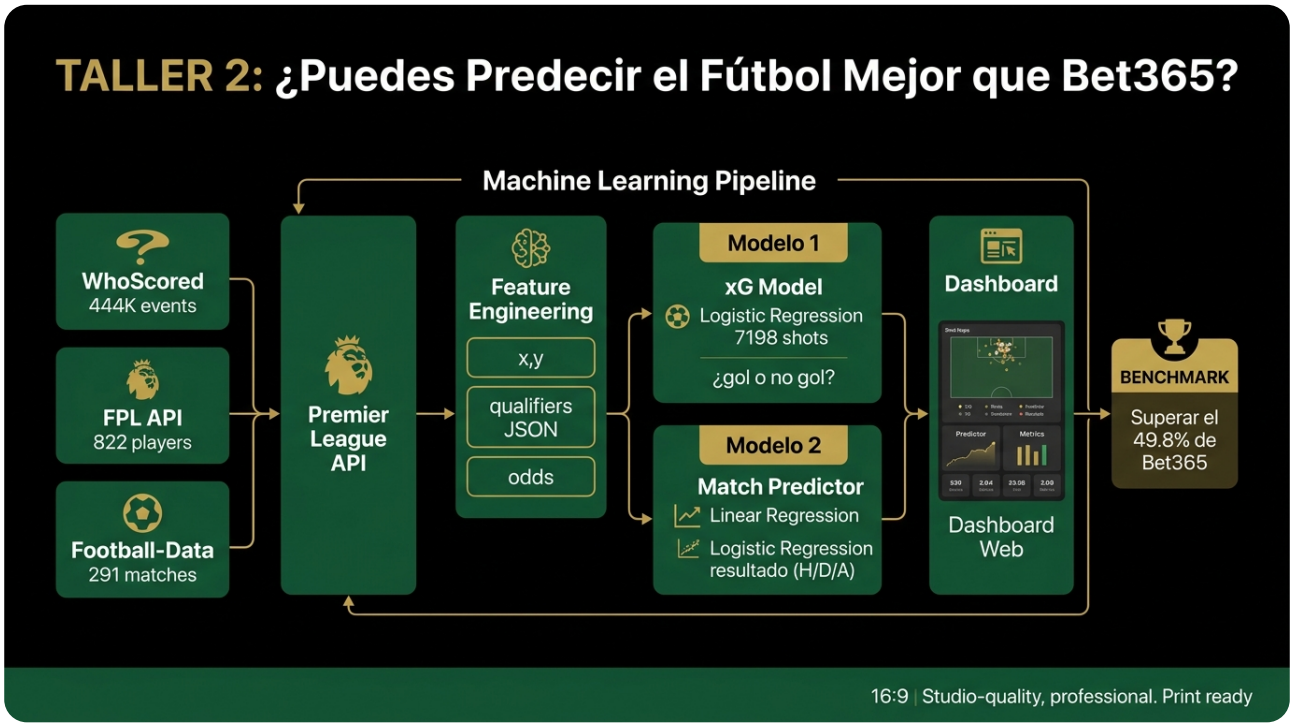

Pipeline completo: desde los datos hasta el dashboard predictivo

1. Contexto

La Premier League 2025-26 es la liga de fútbol más seguida del mundo. Cada partido genera más de 1,500 eventos registrados: pases, tiros, tackles, goles — cada uno con coordenadas (x, y) en una cancha normalizada de 100×100. Cada jugador tiene más de 40 métricas estadísticas. Y las casas de apuestas como Bet365 invierten millones en modelos sofisticados para predecir resultados.

Bet365 acierta el resultado del 49.8% de los partidos esta temporada.

Su misión: construir modelos de Machine Learning que intenten superar ese benchmark utilizando datos reales.

Cuentan con acceso a un **API REST** exclusivo para este curso con tres fuentes de datos:

Fuente	Datos	Volumen
WhoScored	Eventos con coordenadas — pases, tiros, tackles, goles...	444,252 eventos
FPL API	Stats de jugadores — xG, xA, ICT, puntos, precio...	822 jugadores × 40 campos
football-data.co.uk	Partidos, estadísticas de equipo, odds de apuestas	291 partidos × 37 campos

Los datos cubren **30 de 38 jornadas** (GW1 a GW30), con 20 equipos, 807 goles, y 7,198 tiros registrados con coordenadas precisas.

---

2. El Reto

Construir un **pipeline completo de Machine Learning** con dos modelos obligatorios y un dashboard web desplegado públicamente.

Modelo 1: xG — ¿Gol o No Gol? (Regresión Logística)

El **Expected Goals (xG)** es la métrica revolucionaria del fútbol moderno. Mide la probabilidad de que un tiro termine en gol, basándose en la posición del disparo, el ángulo, la distancia y las circunstancias.

De **7,198 tiros** en la temporada, solo **807 terminaron en gol** — una tasa de conversión del **11.2%**.

Objetivo: Entrenar un modelo de regresión logística que prediga `P(gol | tiro)`.

Dataset: Todos los eventos con `is_shot = true` del API (7,198 registros).

Features mínimas sugeridas (punto de partida):

- **Distancia al arco:** `√((100 - x)² + (50 - y)²)`
- **Ángulo respecto al centro del arco:** `atan2(50 - y, 100 - x)`
- **¿Cabezazo?** (qualifier `Head`)
- **¿Pie derecho o izquierdo?** (qualifiers `RightFoot` / `LeftFoot`)

- **¿Es BigChance?** (qualifier `BigChance`)
- **¿Es penal?** (qualifier `Penalty`)
- **Zona del disparo:** BoxCentre, OutOfBoxCentre, SmallBoxCentre...

Pero hay **110 tipos de qualifiers** — ¿cuáles aportan información? Eso lo descubren ustedes.

Evaluación esperada del modelo:

- Accuracy, Precision, Recall, F1-Score
- Matriz de confusión
- Curva ROC y AUC
- Comparación con el **baseline naive**: predecir siempre "no gol" da 88.8% de accuracy. ¿Pueden hacer algo más inteligente que eso?

Modelo 2: Match Predictor — ¿Quién Gana el Partido?

Parte A — Regresión Lineal: Predecir el número total de goles de un partido (variable continua).

Parte B — Regresión Logística: Predecir el resultado: **Home (H)**, **Draw (D)** o **Away (A)** (clasificación multiclase).

Dataset: 291 partidos con estadísticas + odds de apuestas completas.

El benchmark a superar: Bet365 acierta el **49.8%**. Si su modelo logra **>50% con validación cruzada honesta**, están haciendo algo bien.

Features disponibles directamente en la tabla `matches`:

- Shots, shots on target, corners, fouls, cards (home y away)
- Odds de apuestas: Bet365, BetWay, Max, Average (**12 variables de odds**)
- Árbitro del partido (23 árbitros con sesgos estadísticos medibles)

Features derivables (aquí está la verdadera diferencia):

- Agregar datos de `events` por equipo por partido: pass accuracy, progressive passes, big chances, press %, crosses...
- Historial reciente (rolling averages últimos N partidos)
- Team strength ratings de la tabla `teams`

> ⚠ **Advertencia:** Las stats del partido (shots, SOT) describen lo que YA pasó. Para un predictor real, necesitarían stats de partidos ANTERIORES. El diseño de features es parte del reto — piensen bien qué significa "predecir".

Dashboard Web — Desplegar la Inteligencia

Deploy **obligatorio** en Netlify, Vercel, u otra plataforma pública. URL funcionando al momento de la calificación.

Contenido mínimo del dashboard:

1. **Shot Map:** Visualización de tiros en una cancha de fútbol con colores según la probabilidad xG predicha por su modelo
2. **Predictor:** Interfaz donde se seleccionan 2 equipos y el modelo devuelve predicción (probabilidades H/D/A + goles esperados)
3. **Performance:** Métricas de los modelos (accuracy, confusion matrix, comparación vs Bet365)
4. **EDA:** Al menos 3 visualizaciones exploratorias con insights relevantes

---

3. Referencia del API

Base URL

```
https://premier.72-60-245-2.sslip.io
```

> Pueden verificar que funciona visitando la URL en el navegador. Devuelve la documentación interactiva en la raíz.

Endpoints Principales

Endpoint	Descripción
`GET /`	Info del API + directorio de endpoints
`GET /players`	Jugadores con stats
`GET /players/{id}`	Detalle + historial GW por GW

Endpoint	Descripción
`GET /matches`	Partidos con stats + odds
`GET /matches/{id}/events`	Eventos de un partido (~1,500)
`GET /events`	Eventos filtrados (cross-match)
`GET /standings`	Tabla de posiciones
`GET /teams`	20 equipos con ratings
`GET /referees`	Estadísticas de árbitros

Parámetros útiles por endpoint:

- `/players` — `?sort=xG&position=FWD&team=Arsenal&limit=100`
- `/matches` — `?team=Arsenal&result=H&limit=500`
- `/matches/{id}/events` — `?event_type=Pass&team=Arsenal`
- `/events` — `?is_shot=true&is_goal=true&team=Arsenal&limit=10000`

Endpoints de Export (Bulk Download — Recomendados)

Para descargar datasets completos sin paginación:

Endpoint	Filas	Descripción
`GET /export/players`	822	CSV, `pd.read_csv(url)` directo
`GET /export/matches`	291	CSV, stats + 12 odds features
`GET /export/events`	444,252	CSV streaming, **~30s descarga**
`GET /export/player_history`	1,499	CSV, top 50 jugadores GW×GW

Agregar `?format=json` para obtener JSON en vez de CSV.

Carga Rápida en Python

```
import pandas as pd

BASE = "https://premier.72-60-245-2.sslip.io"

# Datasets completos (recomendado: descargar una vez y guardar local)
players = pd.read_csv(f"{BASE}/export/players")
matches = pd.read_csv(f"{BASE}/export/matches")
events  = pd.read_csv(f"{BASE}/export/events")  # ⚠ 444K filas, ~30 seg

# Solo tiros (más rápido que descargar 444K eventos)
import requests
shots_data = requests.get(f"{BASE}/events?is_shot=true&limit=10000").json()
shots = pd.DataFrame(shots_data['events'])
```

> **Tip:** Descarguen los exports al inicio del proyecto y guárdenlos como CSV local. Así no dependen de la conexión al API para trabajar.

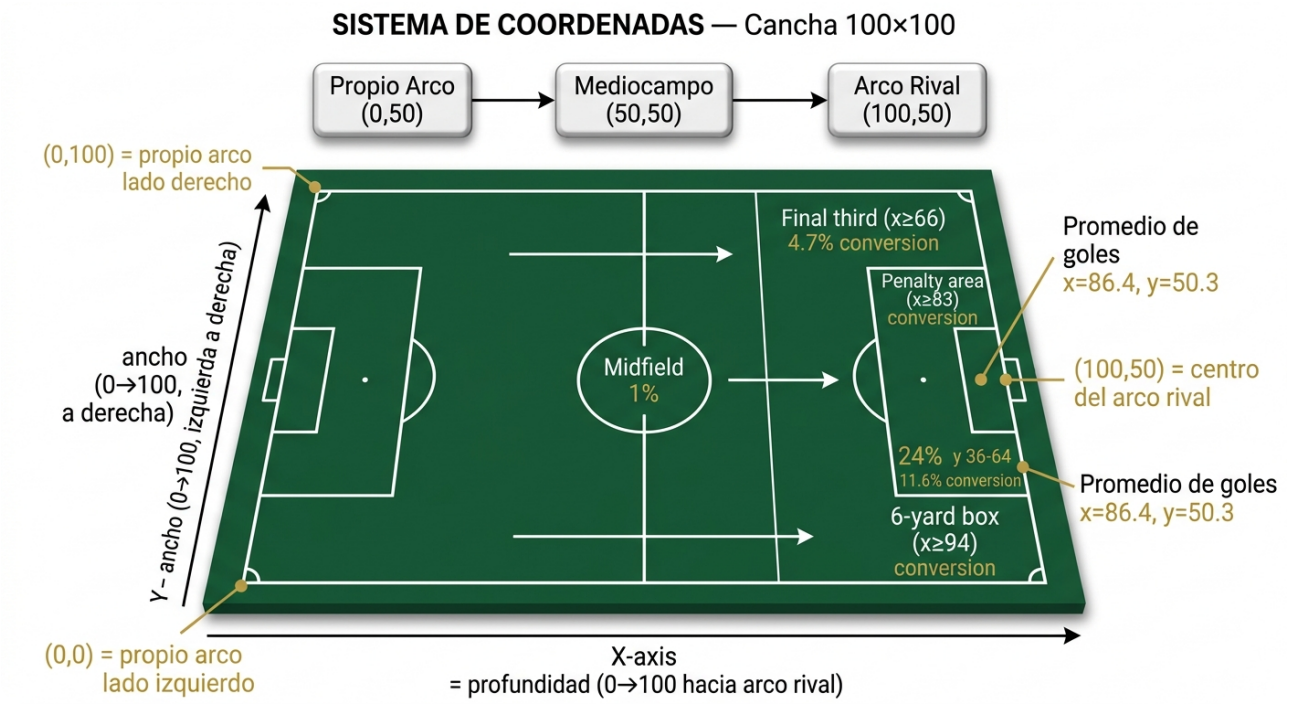

Sistema de coordenadas de la cancha — 100×100, (0,0) esquina propia, (100,50) centro del arco rival

El Campo `qualifiers` — La Mina de Oro

Cada evento tiene un campo `qualifiers` que es un **array JSON** con metadata rica. Ejemplo para un tiro:

```
[
  {"type": {"displayName": "Zone"}, "value": "Center"},
  {"type": {"displayName": "GoalMouthY"}, "value": "52.3"},
  {"type": {"displayName": "GoalMouthZ"}, "value": "8.1"},
  {"type": {"displayName": "BigChance"}},
  {"type": {"displayName": "RightFoot"}},
  {"type": {"displayName": "RegularPlay"}}
]
```

Hay **110 tipos diferentes** de qualifiers en los datos. Algunos de los más relevantes:

Qualifier	Significado
`BigChance`	Oportunidad clara — **predictor #1** de gol
`RightFoot` / `LeftFoot` / `Head`	Parte del cuerpo
`FastBreak`	Contraataque rápido
`FromCorner`	Generado desde corner
`Penalty`	Tiro penal (82.9% conversión)
`FirstTouch`	Tiro a primer toque
`Volley`	Volea
`Zone`	Back / Center / Left / Right
`Length`	Longitud del pase (metros)
`Longball`	Pase largo
`Cross`	Centro al área
`KeyPass`	Pase que genera un tiro
`IntentionalAssist`	Asistencia intencional
`Throughball`	Pase filtrado (creatividad)

Parseo de qualifiers en Python:

```
import json

# Si cargaron desde CSV, qualifiers es string
events['qualifiers_parsed'] = events['qualifiers'].apply(
    lambda x: json.loads(x) if isinstance(x, str) else []
)

# Extraer features booleanas (str.contains sobre JSON)
q = events['qualifiers']
events['is_big_chance'] = q.str.contains(
    'BigChance', na=False).astype(int)
events['is_header'] = q.str.contains(
    '"Head"', na=False).astype(int)
events['is_right_foot'] = q.str.contains(
    'RightFoot', na=False).astype(int)
events['is_left_foot'] = q.str.contains(
    'LeftFoot', na=False).astype(int)
events['is_counter'] = q.str.contains(
    'FastBreak', na=False).astype(int)
events['from_corner'] = q.str.contains(
    'FromCorner', na=False).astype(int)
events['is_penalty'] = q.str.contains(
    '"Penalty"', na=False).astype(int)
events['is_volley'] = q.str.contains(
    'Volley', na=False).astype(int)
events['first_touch'] = q.str.contains(
    'FirstTouch', na=False).astype(int)
```

Sistema de Coordenadas

La cancha es **100 × 100** (normalizada):

- `(0, 0)` = esquina izquierda de tu propio arco
- `(100, 50)` = centro del arco rival
- **x** = profundidad (0→100, de tu arco al rival)
- **y** = ancho (0→100, izquierda a derecha)
- `end_x, end_y` = destino del pase/tiro (disponible en ~66% de eventos)
- `goal_mouth_y, goal_mouth_z` = punto exacto donde entró al arco (solo en tiros)

⚠ Notas Importantes del API

1. **Nombres de equipos difieren entre tablas:** La tabla `matches` usa "Man United" y "Nott'm Forest", pero `events` usa "Man Utd" y "Nottingham Forest". Manejen esto con un diccionario de mapeo.

2. **El campo** `as_` en matches es `away_shots` (renombrado porque `as` es palabra reservada en Python/SQL).
3. **Fechas en matches** están en formato `DD/MM/YYYY`, no ISO. Usar `pd.to_datetime(df['date'], format='%d/%m/%Y')`.
4. `player_history` solo tiene datos de 50 jugadores (los top del Fantasy), no los 822.
5. **Eventos sin ubicación** — Cards, Substitutions, FormationChange, Start, End tienen `x=0, y=0`. Filtrarlos en cualquier análisis espacial.
6. **Los match IDs son internos** (1 a 291), no son los IDs de WhoScored. Usar el endpoint `/matches` para obtener la lista.

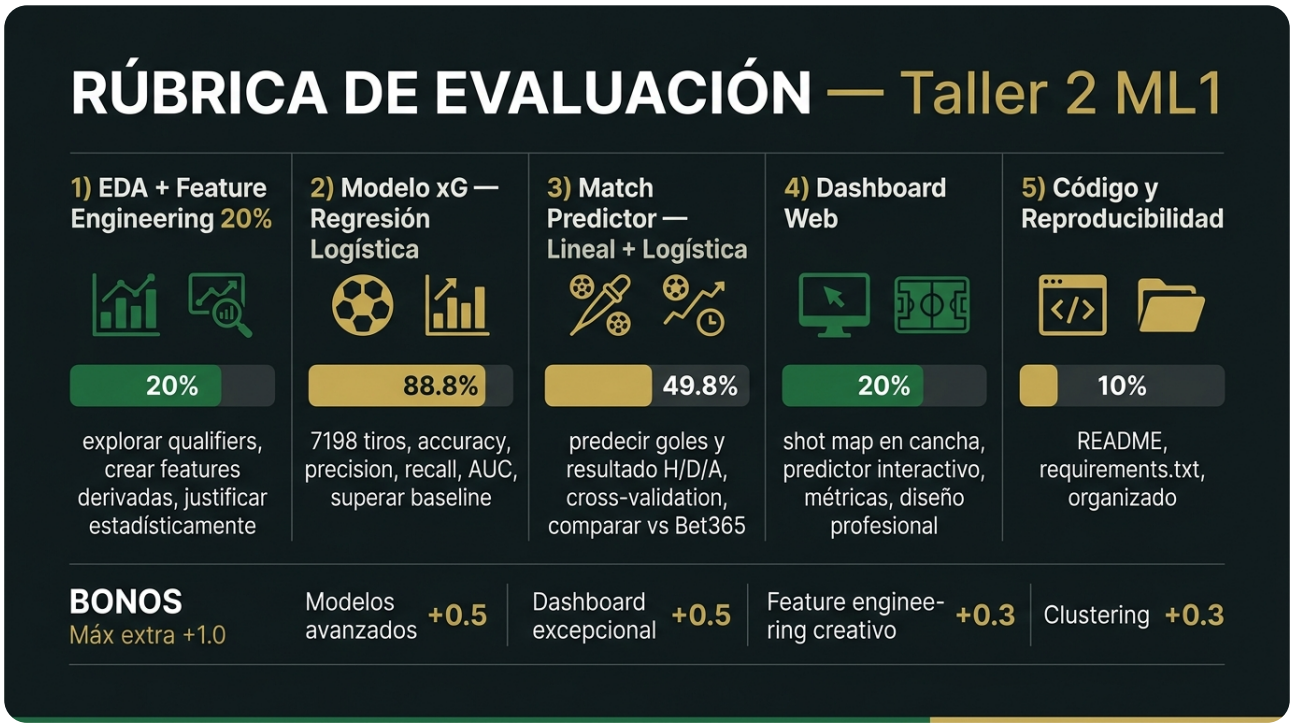

Criterios de evaluación y pesos del Taller 2

4. Rúbrica de Evaluación

Criterios Principales (sobre 5.0)

1. EDA + Feature Engineering (20%)

5.0 Excelente	3.5–4.9 Bueno	2.0–3.4 Aceptable	< 2.0
EDA profundo con insights accionables. Features	EDA adecuado con visualizaciones.	EDA básico (describe,	Sin EDA

5.0 Excelente	3.5–4.9 Bueno	2.0–3.4 Aceptable	< 2.0
creativas de events/ qualifiers con justificación estadística	Algunas features derivadas	histogramas). Solo features directas	

2. Modelo xG — Regresión Logística (25%)

5.0 Excelente	3.5–4.9 Bueno	2.0–3.4 Aceptable	< 2.0
Features bien seleccionadas. Métricas completas (accuracy, precision, recall, F1, AUC). Supera baseline naive	Modelo funcional. Al menos accuracy, confusion matrix y una métrica adicional	Modelo entrenado pero pocas features o métricas incompletas	No funciona

3. Match Predictor — Lineal + Logística (25%)

5.0 Excelente	3.5–4.9 Bueno	2.0–3.4 Aceptable	< 2.0
Ambas regresiones con cross-validation. Comparación vs Bet365 (49.8%). Análisis de residuos	Ambas regresiones funcionales con métricas. Mencionan benchmark	Solo una regresión, o sin validación cruzada	Falta modelo

4. Dashboard Web (20%)

5.0 Excelente	3.5–4.9 Bueno	2.0–3.4 Aceptable	< 2.0
Diseño profesional. Shot map en cancha. Predictor interactivo. UX responsive	Dashboard funcional con 4 secciones mínimas. Diseño aceptable	Básico, faltan secciones o diseño descuidado	URL no funciona

5. Código + Reproducibilidad (10%)

5.0 Excelente	3.5–4.9 Bueno	2.0–3.4 Aceptable	< 2.0
Código limpio, comentado. README completo. `requirements.txt`	Código organizado, lógica comprensible	Funciona pero desorganizado	No ejecutable

Bonificaciones (máximo +1.0 sobre 5.0)

Modelos avanzados (+0.5): Implementar Random Forest, XGBoost, SVM o Neural Network **Y comparar cuantitativamente** vs regresión logística baseline. No basta con importar — deben analizar si mejora y por qué.

Dashboard excepcional (+0.5): Visualizaciones interactivas avanzadas, pitch plots, animaciones, filtros dinámicos, diseño profesional.

Feature engineering creativo (+0.3): Features originales bien justificadas: press %, progressive passes, rolling averages, Expected Threat (xT) o métricas custom.

Clustering (+0.3): Segmentación de jugadores/equipos/partidos con K-Means, DBSCAN o jerárquico. Visualización e interpretación futbolística.

> La nota máxima posible es **6.0/5.0** (5.0 base + 1.0 de bonos).

---

5. Formato de Entrega

¿Qué entregar?

1. Repositorio GitHub (público o con acceso concedido al profesor)

- Notebook(s) `.ipynb` con EDA completo + entrenamiento de modelos
- Código fuente del dashboard
- `README.md` con:
  - Nombres completos y códigos de los integrantes
  - URL del dashboard desplegado
  - Descripción breve del approach y features utilizadas
  - Instrucciones para ejecutar los notebooks
- `requirements.txt` con dependencias

2. URL del Dashboard funcionando en Netlify, Vercel, Streamlit Cloud, u otra plataforma

- Debe estar activo al momento de la calificación
- Si la URL se cae, se califica con lo disponible en el repositorio

3. Formulario de entrega (se compartirá por Teams)

- Link del repositorio
- URL del dashboard
- Nombres de integrantes

Fecha Límite

Domingo 29 de marzo de 2026, 11:59 PM (hora Colombia, GMT-5)

Penalizaciones por Entrega Tardía

Retraso	Penalización
0 – 12 horas	**-0.5** sobre la nota final
12 – 24 horas	**-1.0** sobre la nota final
24 – 48 horas	**-1.5** sobre la nota final
Más de 48 horas	**No se recibe**

> La hora de entrega se determina por el **más tardío** entre: el último commit en el repositorio Y el momento de envío del formulario.

Política de Integridad Académica

- El trabajo es en **parejas**. Ambos integrantes deben poder explicar cualquier parte del código si se les pregunta.
- **Pueden usar herramientas de IA** (ChatGPT, Copilot, Claude) como apoyo, pero el diseño de features, la selección de modelos y la interpretación de resultados deben demostrar comprensión propia.
- Si dos equipos entregan código sustancialmente idéntico (más allá de lo que provee este enunciado), **ambos equipos reciben 0.0**.
- Se valora la **originalidad del approach**, no reproducir tutoriales.

---

6. Tips y Consejos

Sobre los Datos

1. Empiecen por los exports. Un `pd.read_csv(f"{BASE}/export/matches")` les da el dataset completo listo para trabajar. No se compliquen con paginación en la primera exploración.

2. Guarden los datos localmente. Descarguen los CSVs una vez y trabajen offline. Así no dependen de la conexión al API y pueden iterar más rápido.

3. Los 291 partidos son pocos para ML. Con datasets pequeños, **cross-validation** (k-fold, k ≥ 5) es obligatorio. Un solo train/test split les puede dar resultados engañosos.

4. La mina de oro son los qualifiers. Los equipos que parseen los qualifiers JSON y extraigan features como BigChance rate, cross accuracy, pass length distribution, pressing intensity... tendrán una ventaja significativa sobre quienes solo usen columnas directas.

Sobre los Modelos

5. El baseline con solo odds ya da ~50%. Las odds de Bet365 codifican información valiosa. La pregunta interesante es: ¿qué features **agregan valor por encima de las odds**? Ahí está el reto real.

6. Los empates son el enemigo. El 26.1% de los partidos terminan en Draw y son casi imposibles de predecir con datos. Consideren: ¿es mejor predecir 3 clases (H/D/A) o simplificar a 2 (HomeWin / NotHomeWin)?

7. El desbalance de clases en xG es real. Solo el 11.2% de los tiros son gol. Un modelo que diga "nunca es gol" tiene 88.8% de accuracy pero es inútil. Usen métricas como **Precision, Recall, AUC** y piensen en umbrales de decisión.

8. Regularización importa. Con pocas muestras y muchas features, overfitting es un riesgo real. Usen `LogisticRegression(penalty='l2', C=...)` o `Ridge` / `Lasso` para regresión lineal.

9. ⚠ Cuidado con data leakage. Si usan stats del partido (shots, SOT) para predecir el resultado de **ese mismo partido**, están haciendo trampa — esos datos solo existen después del partido. Para un predictor honesto, usen datos de partidos **anteriores**.

Sobre el Dashboard

10. Prioricen funcionalidad sobre estética. Un dashboard deployed con modelos funcionando vale más que un mockup bonito sin ML detrás.

11. Pre-computen las predicciones. No necesitan correr el modelo en vivo en el servidor. Pueden generar un JSON con todas las predicciones y servirlo como archivo estático.

12. Un shot map en cancha impresiona. Librerías como `mplsoccer` (Python) generan visualizaciones profesionales de cancha. Para la web, pueden pre-generar las imágenes o usar JavaScript con Canvas/SVG.

Sobre el Deploy

13. Netlify/Vercel sirven contenido estático gratis. Pueden generar su dashboard como HTML + CSS + JS + archivos JSON con datos, y hacer deploy sin necesidad de backend.

14. Streamlit Cloud es otra opción si prefieren quedarse en Python. Más simple de deployar, pero un dashboard HTML/JS custom bien hecho demuestra mayor habilidad técnica.

15. Alternativas avanzadas: FastAPI/Flask como backend + React/Svelte/Vue como frontend. Más complejo pero impresionante si lo logran.

---

7. Datos de Referencia Rápidos

Para que tengan contexto al explorar los datos:

Métrica	Valor
Partidos jugados	291 / 380
Goles totales	807 (2.77 por partido)
Home wins	42.3%
Draws	26.1%
Away wins	31.6%
Over 2.5 goals	54.0%
Shot conversion	11.2%
BigChance conversion	36.6%
Penalty conversion	82.9%

Métrica	Valor
Goles 2do tiempo	56.3%
Tipos de eventos	39
Tipos de qualifiers	110
Bet365 accuracy	**49.8%** ← su benchmark

---

8. Bibliografía y Recursos

Referencias Académicas

1. **Dixon, M. & Coles, S.** (1997). Modelling association football scores and inefficiencies in the football betting market. Journal of the Royal Statistical Society: Series C, 46(2), 265-280.
2. **Maher, M.** (1982). Modelling association football scores. Statistica Neerlandica, 36(3), 109-118.
3. **Brechot, Q. & Flepp, R.** (2020). Dealing with randomness in match outcomes: How to rethink performance evaluation in European club football using expected goals. Journal of Sports Economics, 21(5), 479-500.
4. **Rathke, A.** (2017). An examination of expected goals and shot efficiency in soccer. Journal of Human Sport and Exercise, 12(2proc), S514-S529.

Recursos Técnicos

1. **Soccermatics** — David Sumpter. Libro y código Python sobre modelos matemáticos en fútbol. Capítulos sobre xG, passing networks y modelos predictivos.
2. **Friends of Tracking** — Canal de YouTube con tutoriales de football analytics por académicos. Incluye implementaciones de xG, pitch control y tracking data. `youtube.com/@friendsoftracking755`
3. **StatsBomb Open Data** — Datos event-level gratuitos para practicar análisis. Formato similar al de WhoScored. `github.com/statsbomb/open-data`
4. **Expected Goals Philosophy** — James Tippett. Introducción accesible al concepto de xG y su impacto en el análisis del fútbol moderno.

Documentación de Librerías

1. **scikit-learn** — Regresión lineal, logística, métricas, cross-validation. `scikit-learn.org/stable/user_guide.html`
2. **mplsoccer** — Visualizaciones profesionales de cancha: shot maps, heatmaps, pass networks. `mplsoccer.readthedocs.io`
3. **Plotly** — Gráficos interactivos ideales para dashboards web. `plotly.com/python/`
4. **pandas** — Manipulación de datos tabular. `pandas.pydata.org/docs/`

Librerías Recomendadas (pip install)

Librería	Uso
`pandas`, `numpy`	Manipulación de datos
`scikit-learn`	Modelos, métricas, cross-validation
`matplotlib`, `seaborn`	Visualizaciones estáticas
`mplsoccer`	Pitch plots, shot maps
`plotly`	Gráficos interactivos para web
`requests`	Consumir el API

---

9. Preguntas Frecuentes

¿Podemos usar datos externos además del API? Sí, pueden enriquecer con datos de FBref, Transfermarkt, Understat u otras fuentes, siempre que documenten la fuente en el README. Pero los modelos base deben usar datos del API.

¿El dashboard tiene que ser interactivo? Lo mínimo es que muestre las visualizaciones y resultados estáticos. La interactividad (seleccionar equipos, filtrar datos, tooltips) es bonus.

¿Qué pasa si el API se cae? Descarguen los exports al inicio y trabajen con CSVs locales. Esa es su copia de seguridad.

¿Podemos usar AutoML (H2O, AutoSklearn)? No para los modelos base. La regresión lineal y logística deben implementarse con `scikit-learn` de forma explícita para demostrar comprensión. Para los **bonos** de modelos avanzados, pueden usar cualquier herramienta.

¿Podemos ser 3 en el grupo? No. Máximo 2 personas. Si el número de estudiantes es impar, habrá un grupo de 1 con consideración en la calificación proporcional.

¿El modelo tiene que correr en vivo en el dashboard? No. Pueden pre-computar todas las predicciones, guardarlas como JSON/CSV, y que el dashboard simplemente las muestre. Esto simplifica enormemente el deploy.

> "El fútbol es un juego simple complicado por los que intentan hacerlo complejo." — Johan Cruyff
>
> "El Machine Learning es un juego complejo simplificado por los que entienden sus datos." — ML1-2026I

Éxitos. Que gane el mejor modelo.